

TEMA 4

Process Mining

Descoberta de Processos e Conformance Checking
Aplicados ao BPI Challenge 2017

Grupo G5

Michelangelo · João Marcos · André · Daniel

Sumário

Tópicos abordados na apresentação

1. Introdução ao Process Mining

Contexto, conceitos fundamentais e motivação

2. Dataset: BPI Challenge 2017

Processo de concessão de empréstimos e adaptação metodológica

3. Metodologia e Implementação

Pipeline de 7 etapas — pm_toolkit.py

4. Análise Exploratória (EDA)

Frequência, duração dos casos e variantes

5. Process Discovery

DFG, Alpha Miner e Inductive Miner

6. Conformance Checking

Fitness, Precision, Generalization, Simplicity e desvios

7. Performance Analysis e Gargalos

Tempo de espera e identificação de bottlenecks

8. Síntese, Limitações e Conclusão

Insights gerenciais e trabalhos futuros

O que é Process Mining?

Extraindo conhecimento real de processos a partir de dados

Ideia central: cada vez que alguém executa uma tarefa no sistema, fica registrado — quem fez, o quê e quando.

Process Mining analisa esses registros para revelar como o processo realmente acontece, não como foi planejado.

O Problema

Empresas desenham processos ideais no papel
Na prática, os funcionários seguem caminhos diferentes
Ninguém percebe — até aparecer um gargalo ou erro

Process Mining usa os logs do sistema para mostrar
o processo real, com todos os desvios e atrasos

3 Subtarefas Centrais

Process Discovery
Descobrir o modelo real a partir do log
Conformance Checking
Comparar o modelo real com o planejado
Performance Analysis
Medir tempos e identificar gargalos

Event Log
(dados brutos)

Algoritmos
de PM

Modelo do
Processo Real

Dataset: BPI Challenge 2017

Adaptação metodológica por restrição de rede

BPI Challenge 2017 (original)

Log real de concessão de empréstimos
Instituição financeira holandesa
31.509 casos | 1.202.267 eventos
26 atividades — 3 sub-processos:
Application / Offer / Workflow
Dataset padrão acadêmico (4TU ResearchData)

Adaptação Adotada

Sem acesso à internet no ambiente usado
Impossível instalar PM4Py ou baixar .xes
Solução: log sintético determinístico (seed=42)
3.000 casos | 54.597 eventos | 23 atividades
Preserva: vocabulário, laços, ramificações
Validade estrutural, não quantitativa absoluta

Todas as limitações desta adaptação são documentadas no relatório (Seção 6 — Limitações).

Metodologia

Pipeline em 7 etapas



Ferramentas e Implementação

Python 3 | pandas / numpy | matplotlib / seaborn | graphviz
pm_toolkit.py — biblioteca própria: DFG, Alpha Miner, Inductive Miner,
conformance checking e performance analysis implementados do zero
Objetivo: independência de bibliotecas externas (PM4Py indisponível)

Análise Exploratória — Visão Geral

3.000 casos · 54.597 eventos · 23 atividades

3.000

casos

54.597



eventos

18,20

eventos/caso

169


variantes




Distribuição temporal dos eventos

Análise Exploratória — Duração e Variantes

Lead time e distribuição de variantes de execução



Duração média: 4,82 dias (mediana 4,14 d)
P90: 8,43 d | Máximo: 39,17 d
Cauda longa indica laços de re-trabalho




169 variantes distintas de execução
Top 1 variante: 19,33% dos casos
Top 5 variantes: 44,47% dos casos
Distribuição de cauda longa típica


Process Discovery — DFG

Directly-Follows Graph: cada seta = uma sequência observada no log

DFG Completo
Todas as sequências observadas, incluindo raras.
Setas mais grossas = sequências mais frequentes.



DFG Filtrado ($\geq 10\%$ de frequência)
Só o caminho principal — como a maioria dos casos flui.
Equivale ao Heuristic Miner: ignora sequências raras.



Alpha Miner — Rede de Petri

Modelo formal com lugares (condições) e transições (atividades)

Como ler o grafo

Quadrados laranja = atividades
Círculos verdes = condições
(ex.: 'oferta enviada')


O algoritmo analisa:
Quem vem antes de quem?
Quem ocorre em paralelo?
Quem nunca ocorre junto?

Ponto fraco: não lida bem com
laços curtos e repetições

Resultado para o BPI17:

23 atividades gerou 23 condições — estrutura densa, reflexo dos laços de re-trabalho.

Fitness: 1,000 | Precision: 1,000 | Simplicity: 0,906 — melhor equilíbrio entre os modelos testados.





Conformance Checking — Resultados

Comparação entre os modelos descobertos

Modelo	Fitness	Precision	Generaliz.	Simplicity	Arestas
DFG filtrado (Heuristic)	0,9893	1,0000	1,0000	0,9149	24
Alpha Miner	1,0000	1,0000	1,0000	0,9058	29
Inductive Miner	0,9973	0,0664	0,0664	0,1938	422
⚠ Inductive Miner caiu no 'modelo flor': permite qualquer sequência → fitness alta, mas precision quase zero.					
Fitness mede: 'o modelo consegue reproduzir o que aconteceu no log?' Precision mede: 'o modelo só permite o que realmente acontece?' Inductive Miner (fitness=0,997 / precision=0,066): Aceita quase tudo — inclusive sequências impossíveis na prática Alpha Miner (fitness=1,0 / precision=1,0 / 29 arestas): Modelo mais útil — representa exatamente o que foi observado					

Conformance Checking — Desvios



Top desvios contra o modelo DFG filtrado



Laço de múltiplas ofertas (267 ocorr.): estruturalmente esperado no processo de empréstimos
Omissão de W_Handle leads (171): via alternativa conhecida
Ramificação de análise de fraude (126/78/48): exceção rara, mas processualmente distinta

Performance Analysis — Gargalos

Tempo de espera entre atividades consecutivas



O que os dados revelam:

- Maior gargalo: após enviar a oferta, o cliente demora em média 1,27 dias para ser contatado
- Todos os atrasos estão em etapas humanas — ligações, validação de documentos
- Etapas automáticas (criar oferta, enviar email) levam segundos
- Conclusão prática: mais atendentes ou automação da triagem reduziria o tempo total do processo

Análise Crítica — O que os resultados significam?

Além dos números: interpretação e implicações

O processo real é muito mais caótico que o planejado

169 variantes — só 19,3% seguem o fluxo ideal. Os outros 80,7% desviam por re-trabalho, múltiplas ofertas ou fraude.

Por que isso importa? Um gestor que só olha o fluxograma não enxerga a complexidade real do dia a dia.

Os gargalos são humanos, não tecnológicos

Todas as etapas automáticas (criar oferta, enviar email) levam segundos. Os atrasos estão nas ligações e validações.

Por que isso importa? Investir em mais servidores não resolve. O problema é de capacidade humana e triagem.

Alta fitness não garante modelo útil — cuidado com o modelo flor

Inductive Miner: fitness 99,7% mas precision 6,6%. O modelo aceita praticamente qualquer sequência de atividades.

Por que isso importa? Uma métrica boa isolada pode enganar. É preciso analisar o conjunto fitness + precision.

A escolha do algoritmo depende do objetivo

Alpha Miner revelou o processo de forma compacta (29 arestas). Inductive Miner é mais formal, mas menos útil aqui.

Por que isso importa? Não existe algoritmo universalmente melhor — o contexto define a escolha.

Limitações — Honestidade Metodológica

O que afeta os resultados e como mitigar

Log sintético, não o BPI17 real

Sem internet no ambiente de execução — impossível baixar o arquivo original (~1 GB).

Impacto: números absolutos não comparáveis à literatura. Padrões qualitativos preservados.

Volume reduzido: 3.000 casos vs. 31.509 reais

Restrição de desempenho computacional do ambiente sem bibliotecas otimizadas.

Impacto: algumas métricas estatísticas podem ser menos robustas em dados reais.

Algoritmos implementados do zero, sem PM4Py

PM4Py indisponível. Implementações didáticas — não validadas contra benchmark.

Impacto: valores de fitness/precision são aproximações, não resultados de produção.

Heuristic Miner não implementado separadamente

Representado pelo DFG filtrado por frequência — conceito equivalente, não idêntico.

Trabalho futuro: implementar com métricas de dependência estatística formais.

Conclusão

- Pipeline completo de Process Mining: EDA, descoberta, conformance e performance
- 169 variantes de execução — processo real substancialmente mais complexo que o ideal
- Gargalos em etapas humanas com espera média superior a 25 horas
- Trade-off fitness/precision: Inductive Miner (0,997/0,066) vs Alpha Miner equilibrado
- Metodologia robusta mesmo sem PM4Py e sem dataset real — limitações explicitadas

Obrigado!

Perguntas?

Grupo G5 — Process Mining — Tema 4 — Mineração de Dados — UNIFESSPA

Repositório: github.com/Michelangelo-Costa/ProcessMining-Tema4-G5